物体パーツ集合のアライメントに基づく 3Dアフォーダンスセグメンテーション

荒明 尚輝[*1]、森脇 悠太[*1]、西村 俊彦[*2]、村崎 和彦[*2]、谷田 隆一[*2]、谷口 行信[*1]、入江 豪[*1]

([*1]東京理科大学、[*2]NTT株式会社)

TL;DR

追加の3D学習データや人手によるアノテーションを必要としない、物体パーツ語に基づくプロンプト適応を提案する。
アフォーダンスに関連する物体パーツをより精緻に局所化し、3Dシーンアフォーダンスセグメンテーションを改善した。

Task

3Dシーン点群



言語クエリ



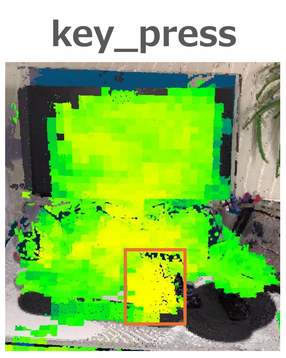


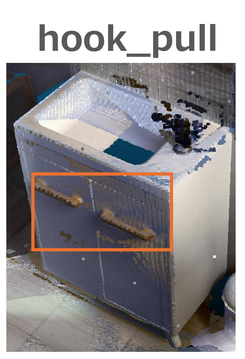
3Dアフォーダンスセグメンテーション

点群の各点がどのアフォーダンス(押す、引く、座るなど)に対応するかを推定する問題

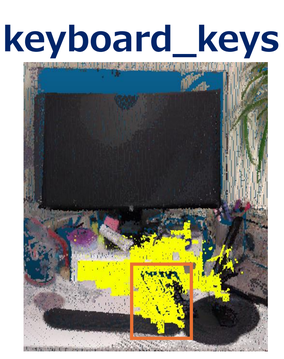
Challenge & Insight

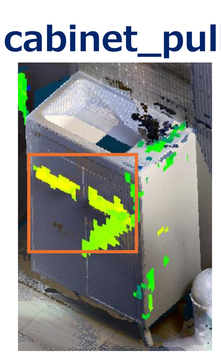
アフォーダンス語





物体パーツ語







✕ 物体全体に反応/反応なし　✓ 対象部位に局所化

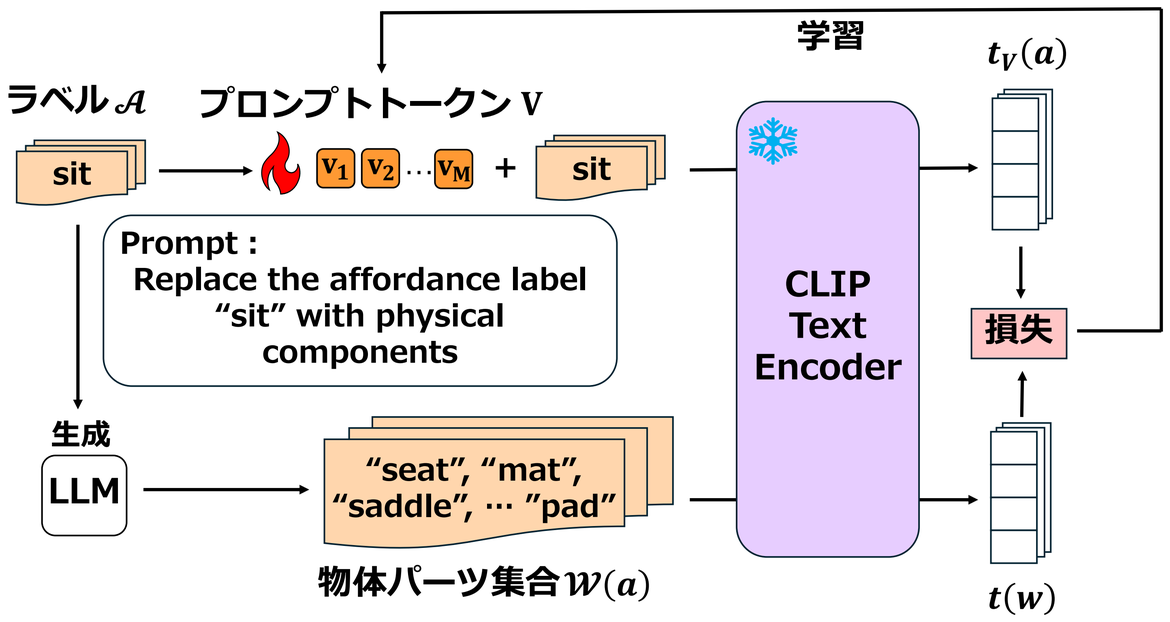
提案：アフォーダンス表現を物体パーツ語の表現に近づける

Method

大規模言語モデル（LLM）が生成した物体パーツ集合を教師として、プロンプトトークンVのみを学習する

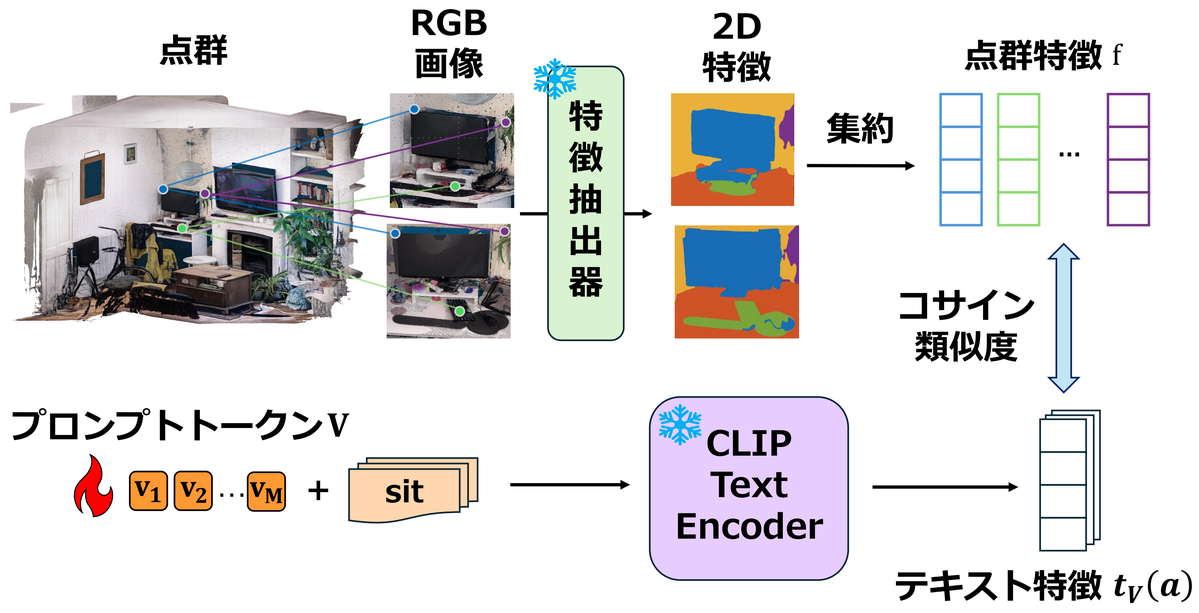
固定パラメータ　学習可能パラメータ

プロンプトトークンの学習



CLIPテキストエンコーダは固定し、
プロンプトトークンVのみを学習する

アフォーダンスの推論



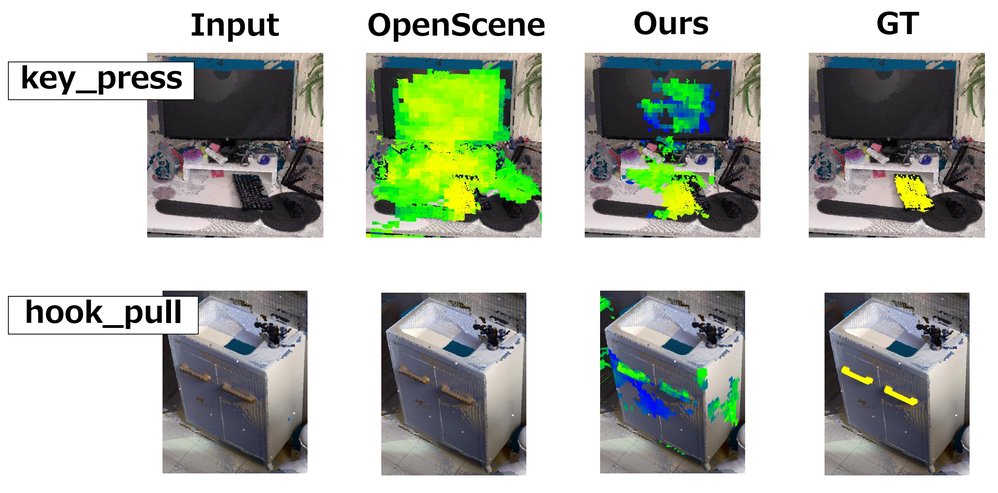
学習したプロンプトトークンVを
アフォーダンスラベルに付加する

Results on SceneFun3D

R1 mIoUは全6条件で改善し、mAccは5/6条件で改善した

特徴抽出器	推論設定	mIoU			mAcc		
		Base	Ours	Δ	Base	Ours	Δ
OpenSeg	Fusion	8.5	9.8	+1.3	14.1	27.1	+13.0
	Distill	5.8	7.0	+1.2	20.3	22.4	+2.1
	Ensemble	6.9	8.7	+1.8	20.7	27.0	+6.3
LSeg	Fusion	1.1	4.0	+2.9	10.5	20.7	+10.2
	Distill	0.8	1.7	+0.9	11.1	9.4	-1.7
	Ensemble	1.0	2.7	+1.7	11.5	11.7	+0.2

R2 物体全体への過剰反応を抑え、対象部位の見逃しを低減



R3 アフォーダンスを物体パーツに置き換えるランダム置換は不安定（例：rotate→handle，key_press→button）

指標	ランダム置換 (平均±標準偏差)	提案手法 (Ours)	差分 (Ours-平均)
mIoU	5.0±2.2	9.8	+4.8
mAcc	15.8±6.2	27.1	+11.3

R4 単純な語集合の集約では性能が大幅に劣化

	Baseline	Text-Mean	Ens-Mean	Ens-Max	Ours
mIoU	8.5	1.5	1.6	5.2	9.8
mAcc	14.1	5.9	6.1	7.6	27.1